

06 주차

GAN 발전 2

상명대학교컴퓨터과학과 민경하



학습목차

- 1. WGAN의 기본 원리
 - 2. WGAN의 설계
- 3. WGAN의 구성 요소 (1): generator
- 4. WGAN의 구성 요소 (2): discriminator
- 5. WGAN의 구성 요소 (3): Gradient penalty
 - 6. WGAN의 구성 요소 (4): loss 함수



1. WGAN의 기본 원리

Entropy의 개념(기초)

- 정보 이론의 기본 개념
 - ☑ m: 정보를 포함하는 message ☑ p(m): m의 확률 ☑ I(m): m에 대한 self-information

$$I(m) = log\left(\frac{1}{p(m)}\right) = -log(p(m))$$

예

- |m| = 1 → 항상 같은 message를 전달 → p(m) = 1 → I(m) = 0
- ☑ $|m| = 2 \rightarrow 2$ 개의 message를 전달 $\rightarrow p(m) = \frac{1}{2} \rightarrow I(m) = log 2 = 1 (1 bit의 용량이 필요)$
- ☑ $|m| = 8 \rightarrow 8$ 개의 message를 전달 $\rightarrow p(m) = 1/8 \rightarrow I(m) = log 8 = 3 (3 bit의 용량이 필요)$



Entropy의 개념(기초)

ullet 메시지 m의 집합 M에 대한 정보량의 평균값 $\to \sum p(m) * I(m)$

$$H(M) = E[I(M)] = \sum_{m \in M} p(m)I(m) = -\sum_{m \in M} p(m)\log p(m)$$

예

- ☑ M = (0, 1) with p(0) = 0.001, p(1) = 0.999 (최소)
 - $> H(M) = -(0.001*log(0.001) + 0.999*log(0.999)) \approx 0.011$
- ☑ M = (0, 1) with p(0) = 0.5, p(1) = 0.5 (최대)
 - > H(M) = -(0.5*log0.5 + 0.5*log0.5) = 1
- M = (0, 1) with p(0) = 0.25, p(1) = 0.75
 - H(M) = -(0.25*log0.25 + 0.75*log0.75) = 0.811

Entropy의 개념(기초)

- Cross entropy
 - ☑ 두 확률 분포 p와 q에 대해서 q를 이용해서 p를 설명할 때 필요한 정보량

$$H(p,q) = E_p[-\log(q)] = -\sum_{x} p(x) \log q(x)$$



2. WGAN의 설계



Wasserstein GAN

- Improves the stability of GAN training
 - Resolve mode collapsing
 - Avoid gradient vanishing



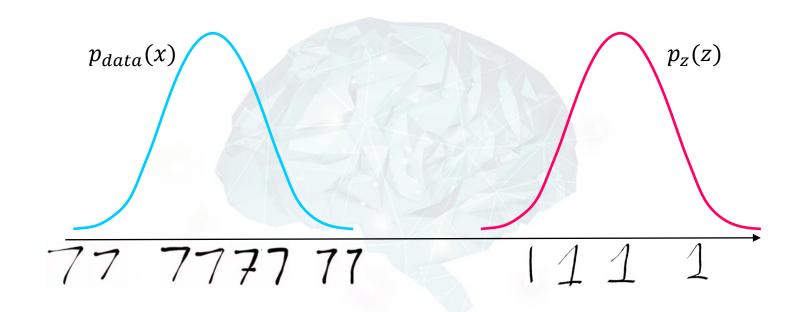
Leonid Wasserstein (1944 ~)

PennState 수학과 교수

GAN의 목적(복습)

$$\min_{G} \max_{D} V(D, G) = \mathbb{E}_{x \sim P_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim P_{z}(z)} \left[\log \left(1 - D(G(z)) \right) \right]$$

 $p_{data}(x)$ 와 최대한 비슷한 $p_z(z)$ 를 만들자

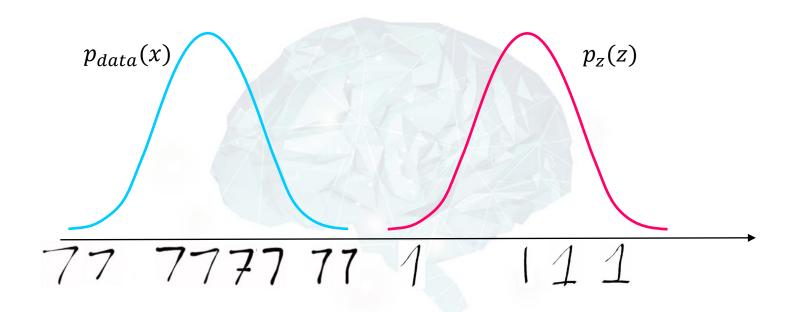




GAN의 목적(복습)

$$\min_{G} \max_{D} V(D, G) = \mathbb{E}_{x \sim P_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim P_{z}(z)} \left[\log \left(1 - D(G(z)) \right) \right]$$

 $p_{data}(x)$ 와 최대한 비슷한 $p_z(z)$ 를 만들자

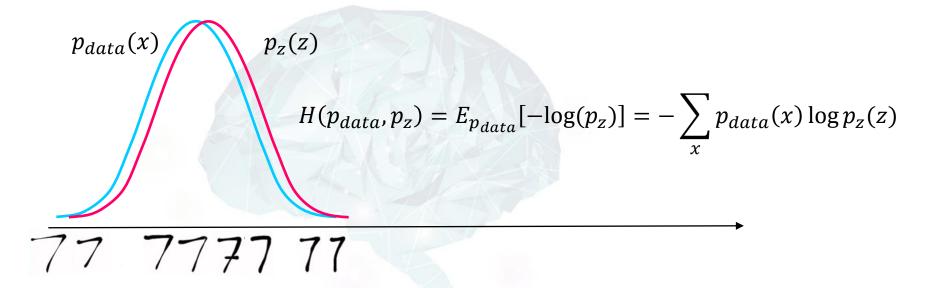




GAN의 목적(복습)

$$\min_{G} \max_{D} V(D, G) = \mathbb{E}_{x \sim P_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim P_{z}(z)} \left[\log \left(1 - D(G(z)) \right) \right]$$

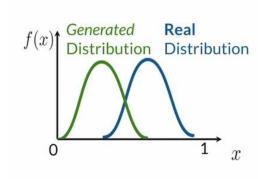
- $p_{data}(x)$ 와 최대한 비슷한 $p_z(z)$ 를 만들자
 - $\rightarrow p_{data}(x)$ 와 $p_z(z)$ 의 거리를 최소로 만들자

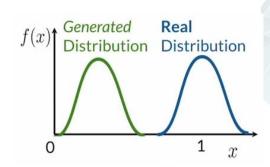


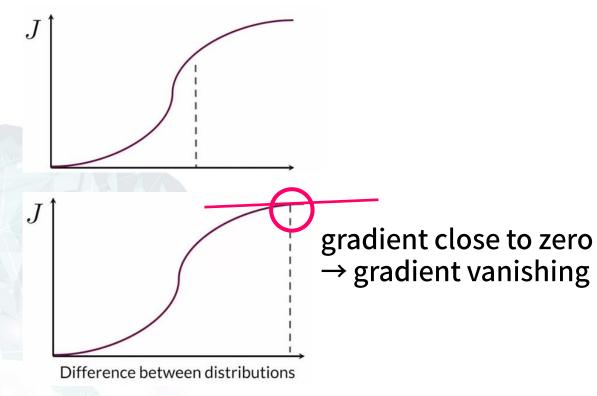


Wasserstein distance

Cross entropy를 이용한 Distribution의 거리 측정의 문제점



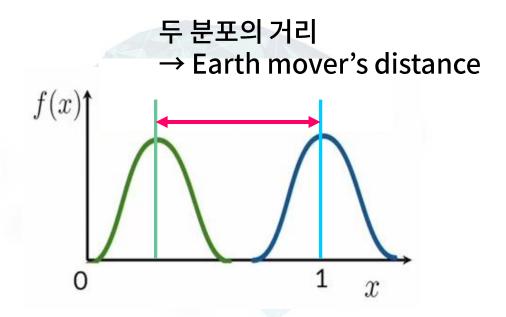






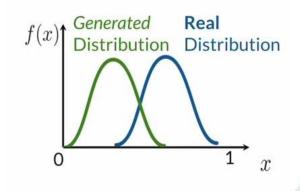
Wasserstein distance

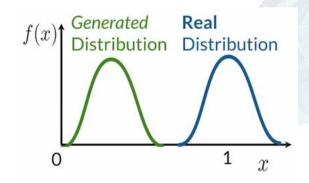
- 해결책 → Earth Mover's Distance
 - ☑ 두 분포의 차이를 두 분포 사이의 거리로 정의
 - ☑ 하나의 분포를 다른 분포로 옮기는 작업을 Earth move로 간주

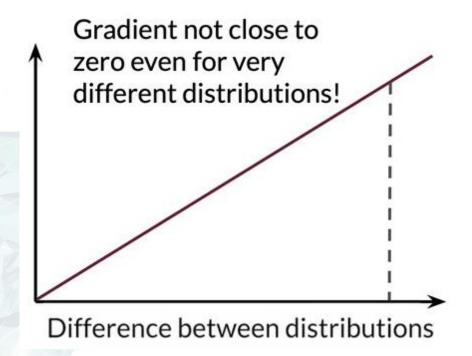




Earth Mover's Distance

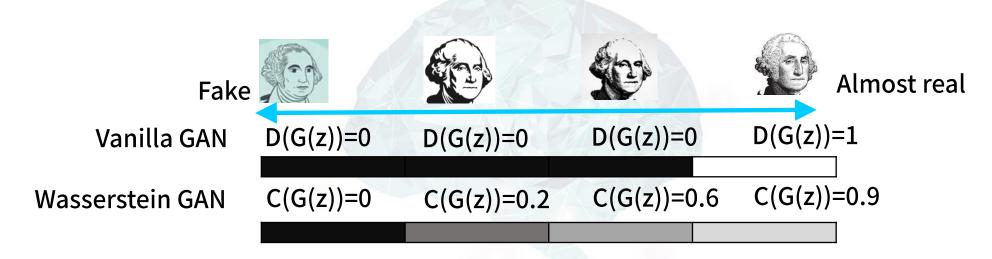






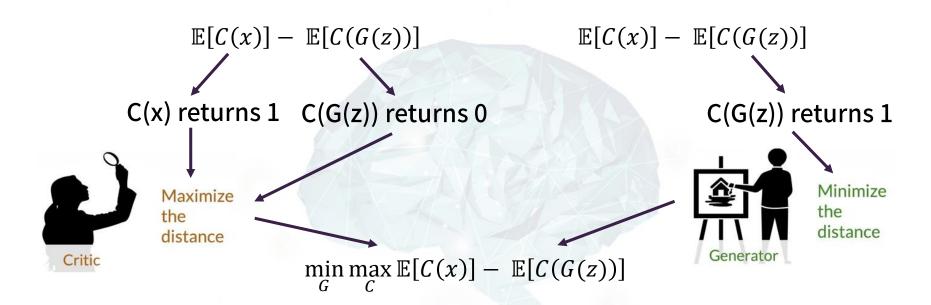
Earth Mover's Distance

- Earth Mover's Distance를 이용해서 정의
- Discriminator → Critic
 - Discriminator return 0 (Fake) or 1 (real)
 - Critic returns the quality of the result in (0, 1)



WassersteinGAN의 loss 함수

- Real data의 distribution과 Fake data의 Distribution의 차이
 - **☑** Real data의 distribution: $\mathbb{E}[C(x)]$
 - **☑** Fake data distribution: $\mathbb{E}[C(G(z))]$

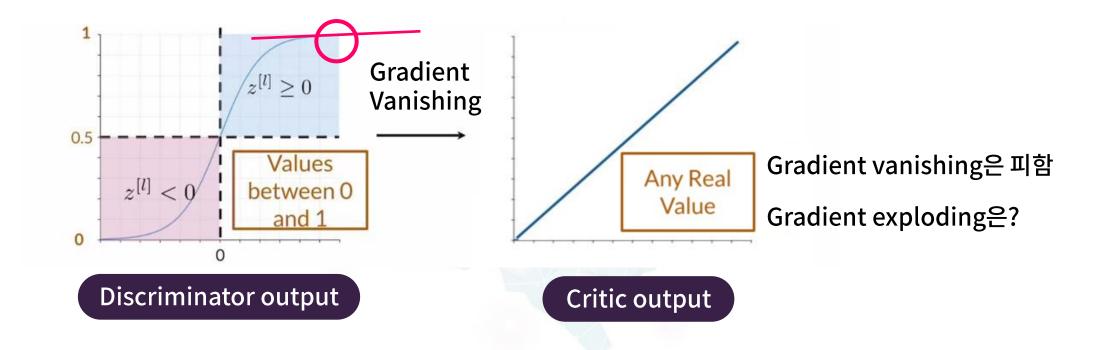


WassersteinGAN의 loss 함수

- Gradient exploding
 - ☑ Gradient가 큰 경우, Gradient descent method를 이용해서 구하는 값이 지나치게 커져서 수렴하지 못하는 경우
- Gradient의 절대값이 1에 가까운 상태를 유지할 것
- 1-Lipschitz continuity

WassersteinGAN의 loss 함수

Comparison of discriminator & critic outputs



Lipschitz 연속 함수

○ 두 점 사이의 거리가 일정한 비율 이상으로 증가하지 않는 함수

$$\left| \frac{dy}{dx} \right| \le K$$



WGAN의 loss함수의 gradient에 1-L 연속을 유지

- Gradient의 크기를 1이하로 유지
 - U Critic의 학습 능력을 제한 (Weight clipping)

Gradient penalty

○ Critic의 gradient에 대한 regularization을 이용해서 1-L 연속을 유지

$$\min_{G} \max_{C} \mathbb{E}[C(x)] - \mathbb{E}[C(G(z))] + \lambda (\|\nabla C(\hat{x})\|_{2} - 1)^{2}$$

Regularization term
→ Gradient penalty term

Gradient penalty에 대한 \hat{x}

G(z)와 x를 보간해서 \hat{x} 생성 \rightarrow G(z)의 품질을 높여서 critic의 학습 속도를 조절

$$\hat{x} = \epsilon x + (1 - \epsilon)G(z)$$

$$\min_{G} \max_{C} \mathbb{E}[C(x)] - \mathbb{E}[C(G(z))] + \lambda (\|\nabla C(\hat{x})\|_{2} - 1)^{2}$$

$$G(z) \qquad \qquad 1 - \epsilon$$

$$\chi \qquad \qquad \chi \qquad \qquad$$



3. WGAN의 구성 요소 (1): generator



Generator block



Generator

```
class Generator(nn.Module):
    def init (self, z dim=10, im chan=1, hidden dim=64):
        super(Generator, self). init ()
       self.z dim = z dim
       self.gen = nn.Sequential (
            self.gen block(z dim, hidden dim*4),
            self.gen block(hidden dim*4, hidden dim*2, kernel size=4, stride=1),
            self.gen block(hidden dim*2, hidden dim),
            self.gen block(hidden dim, im chan, kernel size=4, final layer=True),
    # def gen block
    def forward(self, noise):
       x = noise.view(len(noise), self.z dim, 1, 1)
       result = self.gen(x)
       return result
```



4. WGAN의 구성 요소 (2): discriminator



Critic block



Critic

```
class Critic(nn.Module):
    def __init__ (self, im_chan=1, hidden_dim=64):
        super(Critic, self).__init__()
        self.crit = nn.Sequential(
            self.crit_block(im_chan, hidden_dim),
            self.crit_block(hidden_dim, hidden_dim*2),
            self.crit_block(hidden_dim*2, 1, final_layer=True),
        )

# def crit_block

def forward(self, image):
        crit_pred = self.crit(image)
        return crit_pred.view(len(crit_pred), -1)
```



5. WGAN의 구성 요소 (3): Gradient penalty



Gradient 계산

```
\min_{G} \max_{C} \mathbb{E}[C(x)] - \mathbb{E}[C(G(z))] + \lambda \left( |\nabla C(\widehat{x})|_{2} - 1 \right)^{2}
\widehat{x} = \epsilon x + (1 - \epsilon)G(z)
```

```
def get gradient(crit, real, fake, epsilon):
    # Mix the images together
   mixed images = real * epsilon + fake * (1 - epsilon)
    # Calculate the critic's scores on the mixed images
   mixed scores = crit(mixed images)
    # Take the gradient of the scores with respect to the images
    gradient = torch.autograd.grad(
        inputs=mixed images,
        outputs=mixed scores,
        grad outputs=torch.ones like (mixed scores),
        create graph=True,
        retain graph=True,
    [0]
    return gradient
```



Gradient penalty

```
\min_{G} \max_{C} \mathbb{E}[C(x)] - \mathbb{E}[C(G(z))] + \lambda \left( \|\nabla C(\hat{x})\|_{2} - 1 \right)^{2}
```

```
def gradient_penalty(gradient):
    # Flatten the gradients so that each row captures one image
    gradient = gradient.view(len(gradient), -1)

# Calculate the magnitude of every row
    gradient_norm = gradient.norm(2, dim=1)

# Penalize the mean squared distance of the gradient norms from 1
    penalty = torch.mean((gradient_norm - 1)**2)
    return penalty
```



6. WGAN의 구성 요소 (4): loss 함수

loss 함수 계산

```
def get_gen_loss(crit_fake_pred):
    gen_loss = -1. * torch.mean(crit_fake_pred)
    return gen_loss
```

```
def get_crit_loss(crit_fake_pred, crit_real_pred, gp, c_lambda):
    crit_loss = torch.mean(crit_fake_pred) - torch.mean(crit_real_pred) + c_lambda * gp
    return crit_loss
```

$$\min_{G} \max_{C} \mathbb{E}[C(x)] - \mathbb{E}[C(G(z))] + \lambda \left(\|\nabla C(\hat{x})\|_{2} - 1 \right)^{2}$$